

Øvelser: tekst som data

Social Data Science 1: lektion 7

Øvelserne bruger det datasæt, vi har preprocessed sammen, `ft_lovforslag.csv`: 3.070 debatter fra 1. behandlingen af lovforslag i Folketinget, oktober 2007 til november 2022.

Del A er simple, deskriptive **bag-of-words**-øvelser: tæl ord, find de hyppigste, se på fordelingen.

Del B bygger videre på det, I så i slides, men som mere “rigtige” undersøgelser.

Under **Hjælp** står, hvor I har set de funktioner, I skal bruge:

- **Slides**: lektion 7-slides, med navnet på slidet.
 - **Preprocess-notebooken**: `l7_preprocess_dkparl_trinvis`, med trinnets nummer.
 - **spacy-notebooken**: `l7_spacy_supplement`, med trinnets nummer.
-

Opsætning

Kør cellerne. De indlæser data og definerer stopordslisten fra slides (*Fra tekst til tabel*). Ret stien, så den peger på jeres egen kopi af `ft_lovforslag.csv`.

```
import pandas as pd
import numpy as np
from plotnine import *

sti = "/Users/jeppefl/Library/CloudStorage/OneDrive-
AalborgUniversitet/01_work/01_undervisning/02_sds1/01_slides/lektion-7/
resources/ft_lovforslag.csv"
korpus = pd.read_csv(sti)

print(korpus.shape)
print(korpus.columns.tolist())
```

```
(3070, 9)
['id', 'dato', 'aar', 'samling', 'lovnr', 'titel', 'minister', 'omraade',
'tekst']
```

```
stopord = set("""og i jeg det at en den til er som på de med han af for ikke
der var mig sig men et har om vi min havde ham hun nu over da fra du ud sin
dem
os op man hans hvor eller hvad skal selv her alle vil blev kunne ind når være
dog
```

```
jo dette dig deres end mit også under have dens hvis dine disse hvem vores jer
sådan andre nogle bliver blive kan så ved mod meget rigtig tak hr fru ordfører
ordføreren forslag lovforslag lovforslaget minister ministeren værsgo altså
godt
synes mener bare lige hele netop sige siger"".split()

print(len(stopord), "stopord")
```

104 stopord

Hele materialet er cirka 22 millioner ord. Tabellen med ét ord per række, som I laver i A2 og A4, fylder derfor en del i hukommelsen. Har jeres computer under 8 GB RAM, så arbejd på et udsnit ved at køre denne linje efter indlæsningen:

```
korpus = korpus.sample(1000, random_state=1)
```

Del A: Bag-of-words, deskriptivt

Her gør vi det, I kender fra lektion 6, hvor vi deler teksterne op i ord og tæller. Målet er at få en fornemmelse for materialet, før vi analyserer det.

A1. Overblik over korpuset

Før vi tæller ord, skal vi vide, hvad vi har, herunder hvor mange debatter er der fra hvert politikområde og hvert år?

Opgave:

1. Tæl antallet af debatter per politikområde (omraade).
2. Tæl antallet af debatter per år (aar), sorteret efter år.
3. Lav en krydstabel med år som rækker og politikområde som kolonner.

Hjælp:

- Preprocess-notebooken, trin 9 og 10: `.value_counts()` på omraade og `.value_counts().sort_index()` på aar.
- Slides, *Validering først*: `pd.crosstab()` med to kolonner.

```
# Din kode her
print(korpus["omraade"].value_counts())
print()
print(korpus["aar"].value_counts().sort_index())
```

```

omraade
Andet          1242
Skat           373
Miljø og klima 366
Retsvæsen      361
Beskæftigelse 301
Uddannelse     273
Udlændinge     154
Name: count, dtype: int64

```

```

aar
2007    41
2008   223
2009   204
2010   217
2011   171
2012   229
2013   214
2014   185
2015   192
2016   205
2017   224
2018   235
2019   186
2020   226
2021   209
2022   109
Name: count, dtype: int64

```

```

omraade_aar = pd.crosstab(korpus["aar"], korpus["omraade"])

print(omraade_aar)

```

omraade	Andet	Beskæftigelse	Miljø og klima	Retsvæsen	Skat	Uddannelse	\
aar							
2007	8	5	10	2	11	5	
2008	84	19	25	25	33	25	
2009	69	18	30	26	27	25	
2010	88	29	16	28	23	25	
2011	67	15	21	29	21	10	
2012	101	23	30	23	27	25	
2013	106	13	30	36	15	14	
2014	78	18	21	26	23	19	
2015	84	24	23	17	24	11	
2016	94	16	23	23	16	15	
2017	92	15	31	23	23	19	

2018	98	17	23	34	29	17
2019	76	17	20	16	32	12
2020	83	34	27	20	26	20
2021	76	27	22	20	32	20
2022	38	11	14	13	11	11

omraade Udlændinge
aar

2007	0
2008	12
2009	9
2010	8
2011	8
2012	0
2013	0
2014	0
2015	9
2016	18
2017	21
2018	17
2019	13
2020	16
2021	12
2022	11

Kig efter i viewer: Åbn krydstabellen. Hvilke celler er små? Find kolonnen Udlændinge.

Til diskussion:

- Hvorfor er der færre debatter i 2007 og 2022?
- Hvor mange debatter om Udlændinge er der typisk per år? Hvad betyder det, hvis vi vil sige noget om udviklingen over tid inden for ét område?

Jeres svar:

A2. Fra tekst til ord

Brug opskriften fra slides til at lave teksterne om til én lang Series med ét ord per række. Indekset husker, hvilken debat ordet kom fra.

Opgave:

1. Lav en Series ord: små bogstaver, erstat alt, der ikke er bogstaver, tal eller mellemrum, med mellemrum, del op, og fold ud.
2. Hvor mange **tokens** og hvor mange **typer** er der?
3. Tæl antallet af ord i hver debat, og gem det som en ny kolonne `n_ord` i korpus.
4. Beskriv fordelingen af `n_ord`, og lav en oversigt med antal debatter og medianen af `n_ord` for hvert politikområde.

Hjælp:

- Slides, *Hvordan den scorer*: hele opskriften fra `korpus["tekst"]` til `.explode()`.
- Slides, *Kør den på korpusset*: `.groupby(level=0)` grupperer efter debatten.
- Preprocess-notebooken, trin 5.2: oversigt med `.agg(antal="size", median_tegn="median")`.

```
# Din kode her
ord = (korpus["tekst"].astype(str)
      .str.lower()
      .str.replace(r"^\wæøå ", " ", regex=True)
      .str.split()
      .explode())

print("tokens:", len(ord), "| typer:", ord.nunique())
```

```
tokens: 21882341 | typer: 151811
```

```
korpus["n_ord"] = ord.groupby(level=0).size()

print(korpus["n_ord"].describe().round(0))
```

```
count    3070.0
mean      7128.0
std       7815.0
min        414.0
25%       3101.0
50%       5004.0
75%       8701.0
max      98087.0
Name: n_ord, dtype: float64
```

```
oversigt = (korpus
            .groupby("omraade")["n_ord"]
            .agg(antal="size", median_ord="median")
            .sort_values("median_ord", ascending=False))

print(oversigt)
```

	antal	median_ord
omraade		
Udlændinge	154	6226.0
Retsvæsen	361	5306.0
Skat	373	5269.0

Andet	1242	5042.0
Miljø og klima	366	4841.5
Beskæftigelse	301	4809.0
Uddannelse	273	4328.0

Kig efter i viewer: Sortér korpus efter `n_ord`. Hvilke debatter er de korteste og de længste? Hvad handler de om?

Til diskussion:

- Hvor meget varierer antallet af ord fra debat til debat?
- Hvilke politikområder har de længste debatter? Er antal ord et godt mål for, hvor meget en debat fylder politisk?
- Slides målte temaer *per 1.000 ord*. Hvorfor er det nødvendigt her?

Jeres svar:

A3. De hyppigste ord, og hvad stopordene fjerner

Hvilke ord bruges mest i Folketinget? Først uden at fjerne noget, derefter uden stopord. Vi fører regnskab med tokens og typer, som i spaCy-notebooken.

Opgave:

1. Find de 20 hyppigste ord i ord.
2. Lav tabellen `kaede` og funktionen `tæl()` fra spaCy-notebooken, og tæl ord.
3. Lav en tabel `fjernet_w` med de fjernede stopord og deres antal. Fjern stopordene, gem resultatet som `indhold`, og tæl igen.
4. Find de 25 hyppigste ord i `indhold`.

Hjælp:

- spaCy-notebooken, trin 4: `kaede` og `tæl()`.
- spaCy-notebooken, trin 5.4: `fjernet_w` med `.value_counts().reset_index()`, og filteret `~ ... .isin(stopord)`.
- Slides, *Hvad fylder i scoren?*: `.value_counts().head()`.

```
# Din kode her
print(ord.value_counts().head(20))
```

```
tekst
det    957924
at     943920
er     762277
og     563950
i      556199
der    446215
```

```

vi      403810
for     399975
til     393663
en      346931
jeg     291523
som     278593
ikke    276949
på      276283
har     272387
de      261656
den     257765
af      254366
man     249808
så      236048
Name: count, dtype: int64

```

```

kaede = pd.DataFrame(columns=["trin", "tokens", "typer"])

def tael(trin, former):
    kaede.loc[len(kaede)] = [trin, len(former), former.nunique()]
    print(kaede)

tael("Rå tokens", ord)

```

```

      trin  tokens  typer
0  Rå tokens 21882341 151811

```

```

fjernet_w = ord[ord.isin(stopord)].value_counts().reset_index()

indhold = ord[~ord.isin(stopord)]

tael("+ fjern stopord", indhold)

```

```

      trin  tokens  typer
0  Rå tokens 21882341 151811
1  + fjern stopord 9201183 151707

```

```

print(indhold.value_counts().head(25))

```

```

tekst
noget      55478
få         51562
derfor     50487

```

```
får          41146
mange        39913
været        39763
kommer       39403
dansk        37581
danmark      37286
mere         35591
gerne        35513
dag          34710
forhold      33837
helt         33086
må           32847
gøre         32644
fordi        32093
flere        31873
gør          31240
år           31169
set          30025
selvfølgelig 29434
faktisk      28959
lidt         27775
folkeparti   27611
Name: count, dtype: int64
```

Kig efter i viewer: Åbn fjernet_w. Hvor langt nede på listen skal I, før I finder et ord, I ville have beholdt?

Til diskussion:

- Hvilke ord dominerer, før stopordene er fjernet? Står der noget, der siger noget om politik?
- Fjerner stopordene flest tokens eller flest typer? Er mønsteret det samme som i spaCy-notebooken?
- Hvilke ord i top 25 efter stopordene overrasker jer? Kan I forklare, hvorfor de er der?

Jeres svar:

A4. De hyppigste ord per politikområde

Kan man se forskel på politikområderne ud fra de hyppigste ord? For at koble ordene til områderne laver vi tabellen lang fra slides med ét ord per række og år og område ved siden af.

Opgave:

1. Lav tabellen lang ud fra ord og kobl år og område på fra korpus.
2. Lav indhold om, så den er lang uden stopord.
3. Find de 10 hyppigste ord i hvert politikområde, og vis dem som én liste per område.

Hjælp:

- Slides, *Tre temaordbøger*: `ord.rename("ord").to_frame().join(korpus[["aar", "omraade"]])`.
- spaCy-notebooken, trin 5.6: fjernet_pos med `.groupby(...)[...].value_counts().groupby(level=0).head(10)`.
- Slides, *Hvad handler klyngerne om?*: `.groupby(...)[ "ord"].agg(list)`.

```
# Din kode her
lang = ord.rename("ord").to_frame().join(korpus[["aar", "omraade"]])

indhold = lang[~lang["ord"].isin(stopord)]

print(indhold.head())
```

	ord	aar	omraade
0	forhandlingen	2014	Miljø og klima
0	åbnet	2014	Miljø og klima
0	første	2014	Miljø og klima
0	ordet	2014	Miljø og klima
0	lars	2014	Miljø og klima

```
top10 = (indhold
        .groupby("omraade")["ord"]
        .value_counts()
        .groupby(level=0)
        .head(10)
        .reset_index())

print(top10.groupby("omraade")["ord"].agg(list))
```

omraade	
Andet	[noget, derfor, få, mange, får, været, gerne, ...
Beskæftigelse	[få, noget, derfor, får, arbejde, kommer, mang...
Miljø og klima	[noget, derfor, få, får, forhold, mere, kommer...
Retsvæsen	[noget, derfor, få, været, må, dag, kommer, da...
Skat	[noget, derfor, få, mere, været, danmark, kr, ...
Uddannelse	[derfor, få, noget, mange, får, unge, været, f...
Udlændinge	[danmark, dansk, få, danske, noget, kommer, de...

Name: ord, dtype: object

Kig efter i viewer: Åbn top10 (eller hvad i kalder variabelen), og filtrér på ét område ad gangen.

Til diskussion:

- Hvor mange af de ti hyppigste ord er ens på tværs af områderne?
- Hvilke ord gør det muligt at genkende et område?
- Hvad fortæller det om hyppighed som mål for, hvad der er *særligt* for et område?

Jeres svar:

A5. Få ord bruges meget, mange ord bruges sjældent

Ordfrekvenser er meget skævt fordelt. Det er grunden til, at en document-term matrix er næsten tom (slides, *Document-term matrix*).

Opgave:

1. Hvor mange typer optræder kun én gang i hele korpusset (*hapax*)? Hvor stor en andel af alle typer er det?
2. Hvor stor en andel af alle tokens udgør de 10 hyppigste ord?
3. Beregn dokumentfrekvensen: i hvor mange debatter står hvert ord? Hvor mange typer står kun i én debat?
4. (Valgfri) Tegn ordenes frekvens mod deres rang med logaritmiske akser.

Hjælp:

- spaCy-notebooken, trin 5.7: dokfrekvens og `(dokfrekvens == 1).sum()`.
- Slides, *Document-term matrix*: `ord.rename("ord").reset_index().drop_duplicates()["ord"].value_counts()`.
- Slides, *Tegn det*: plotnine. Brug `scale_x_log10()` og `scale_y_log10()`.

```
# Din kode her
frekvens = ord.value_counts()

print("Hapax:", (frekvens == 1).sum(), "| andel af typer:", round((frekvens == 1).mean(), 3))
print("Top 10's andel af tokens:", round(frekvens.head(10).sum() / frekvens.sum(), 3))
```

```
Hapax: 65878 | andel af typer: 0.434
Top 10's andel af tokens: 0.264
```


```
dokfrekvens = ord.rename("ord").reset_index().drop_duplicates()
["ord"].value_counts()

print("Typer i kun én debat:", (dokfrekvens == 1).sum(), "af", len(dokfrekvens))
```

```
Typer i kun én debat: 78016 af 151811
```

```
plot = frekvens.reset_index(drop=True).rename("frekvens").to_frame()
plot["rang"] = plot.index + 1
```

```
(ggplot(plot, aes(x="rang", y="frekvens"))
+ geom_line()
+ scale_x_log10()
+ scale_y_log10()
+ labs(x="Rang (log)", y="Frekvens (log)", title="Ordfrekvens mod rang")
+ theme_classic())
```



Kig efter i viewer: Åbn frekvens. Rul til bunden. Hvilke slags ord står kun én gang?

Til diskussion:

- Hvad betyder fordelingen for en DTM med én kolonne per type?
- Er ord, der kun står i én debat, støj? Giv et eksempel på, hvornår de kunne være det interessante.

Jeres svar:

A6. Tilbage til teksten: konkordans

Et ord, der tælles, skal også læses i sin sammenhæng. Vi ser på ordet *retssikkerhed*.

Opgave:

1. Tæl, hvor mange gange *retssikkerhed* (inklusive bøjninger som *retssikkerheden*) står i hver debat. Lav en oversigt per politikområde med antal forekomster og antal debatter, der nævner ordet.
2. Hvilket område nævner ordet flest gange? Hvilke enkeltdebatter nævner det mest?
3. Lav en konkordans: find ordet med 60 tegn før og efter, og læs 8 tilfældige eksempler fra det område, der nævner ordet mest.

Hjælp:

- Slides, *Tilbage til teksten*: `.str.findall(r"(?i).\{0,60\}\b\w*krise\w*.\{0,60\}"), .explode(), .dropna()` og `.sample(8, random_state=1)`.
- Preprocess-notebooken, trin 9: `.str.contains()`. Her skal I bruge `.str.count()`, som tæller i stedet.
- Preprocess-notebooken, trin 5.2: `.agg(...)` med navngivne kolonner.

```
# Din kode her
korpus["retssikkerhed"] = korpus["tekst"].str.count(r"(?i)\bretssikkerhed\w*")

oversigt = (korpus
            .groupby("omraade")["retssikkerhed"]
            .agg(forekomster="sum", debatter=lambda s: (s > 0).sum())
            .sort_values("forekomster", ascending=False))

print(oversigt)
print()
print(korpus.nlargest(5, "retssikkerhed")[["aar", "omraade", "titel",
"retssikkerhed"]])
```

			forekomster	debatter
		omraade		
		Andet	1005	263
		Retsvæsen	985	181
		Skat	493	69
		Udlændinge	316	57
		Miljø og klima	175	51
		Beskæftigelse	143	48
		Uddannelse	67	25

		aar	omraade	titel \
2841	2009	Retsvæsen	1. behandling af L 124: Om retsplejeloven (tel...	
3064	2015	Skat	1. behandling af L 13: Om ophævelse af hjemmel...	
1417	2013	Skat	1. behandling af L 212: Om ny klagestruktur på...	
2823	2016	Skat	1. behandling af L 28: Om opfølgning på retssi...	
2438	2013	Andet	1. behandling af L 158: Om forenkling af klage...	

	retssikkerhed
2841	79
3064	67
1417	48
2823	48
2438	42

```

eksempler = (korpus["tekst"]
              .str.findall(r"(?i){0,60}\bretssikkerhed\w*.{0,60}")
              .explode()
              .dropna()
              .str.replace("\n", " "))

oeverst = oversigt.index[0]
fra_omraadet = eksempler[korpus.loc[eksempler.index, "omraade"] == oeverst]

for linje in fra_omraadet.sample(8, random_state=1):
    print("...", linje, "...")

```

```

Exception ignored in: <bound method IPythonKernel._clean_thread_parent_frames
of <ipykernel.ipkernel.IPythonKernel object at 0x107c92f40>>
Traceback (most recent call last):
  File "/Users/jeppefl/Library/Python/3.9/lib/python/site-packages/ipykernel/
ipkernel.py", line 781, in _clean_thread_parent_frames
    def _clean_thread_parent_frames(
KeyboardInterrupt:

```

... res konklusion er, at flere af forsøgene antaster borgerens retssikkerhed og deres krav på en ordentlig service. Disse dele af forsøg ...

... institution foretager sejlads med elever, og dermed styrkes retssikkerheden og mulighederne for at få erstatning ved ulykker som f.eks. ...

... r bare at sige, at det er o.k., og at det må vi ikke krænke retssikkerhedsmæssigt, er det så bare helt konkret o.k., at man markedsfører eufo ...

... nye bestemmelser på psykiatriområdet, som bl.a. skal styrke retssikkerheden og skabe mere tryghed og bedre arbejdsvilkår på de psykiatr ...

... ligområder, og så kan man jo gøre sig forskellige tanker om retssikkerhed, og den diskussion er jeg selvfølgelig villig til at tage. ...

... vicensniveauer i kommunerne og om, hvordan vi sikrer en bedre retssikkerhed, og også om, hvordan vi kan gøre noget i nogle af de sager, ...

... Vi mener, at der er fundet en god balance mellem retssikkerhed og en mere effektiv klagebehandling, og vi forudser, at lov ...

... jeg sige her til sidst, at et andet vigtigt tema for os er

retssikkerheden. Jeg synes, der er meget inspiration at hente i både magtan ...

Kig efter i viewer: Sortér korpus efter retssikkerhed. Læs titlerne på de debatter, der nævner ordet mest.

Til diskussion:

- Havde I forventet det område? Hvad handler retssikkerhed om, når det bruges der?
- Hvor mange debatter står bag tallet? Hvad betyder det for, hvordan tallet kan tolkes?

Jeres svar:

Del B: Udvidelser

Øvelserne bygger videre på det, I så i slides. Hver øvelse tager én metode og gør den mere “nuanceret”.

Øvelserne bruger ord, lang og indhold fra Del A. Kør Del A først.

B1. Nøgleord: hvad er særligt for et område?

A4 viste, at de hyppigste ord er de samme overalt. **Nøgleord** (*keyness*, Hunston) er ord, der er hyppigere i ét delkorpus end i resten. Et enkelt mål er **log-ratio**, som er $\log_2$ af forholdet mellem ordets relative frekvens i området og i resten af korpuset.

$$\text{log-ratio} = \log_2 \frac{(n + 0,5)/N_{\text{område}}}{(n_{\text{rest}} + 0,5)/N_{\text{rest}}}$$

En log-ratio på 1 betyder, at ordet er dobbelt så hyppigt i området som i resten. Værdien 0,5 indgår i ligningen, så vi ikke dividerer med 0, når et ord slet ikke står i resten.

Opgave:

Brug indhold (uden stopord).

1. Tæl, hvor mange gange hvert ord står i hvert område: en tabel med kolonnerne omraade, ord og n.
2. Tilføj `N_omr` (antal ord i området i alt) og `n_all` (ordets antal i hele korpuset).
3. Beregn `n_rest`, `N_rest` og `log_ratio`.
4. Behold ord med `n >= 50`, og find de 8 ord med højest log-ratio i hvert område.

Hjælp:

- Slides, *TF-IDF*: `dtm.div(dtm.sum(axis=1), axis=0)` giver relative frekvenser, og `np.log()`. Her skal I bruge `np.log2()`.
- `.groupby(...)[“n”].transform(“sum”)` giver summen for gruppen på hver række, så den kan bruges i en beregning række for række.
- `spaCy`-notebogen, trin 5.6: `.groupby(level=0).head(10)`. Her grupperer I på “omraade”.

```
# Din kode her
n = indhold.groupby(["omraade", "ord"]).size().rename("n").reset_index()
```

```
n["N_omr"] = n.groupby("omraade")["n"].transform("sum")
n["n_alle"] = n.groupby("ord")["n"].transform("sum")
n["n_rest"] = n["n_alle"] - n["n"]
n["N_rest"] = n["n"].sum() - n["N_omr"]
```

```
n["log_ratio"] = np.log2(((n["n"] + 0.5) / n["N_omr"]) /
                        ((n["n_rest"] + 0.5) / n["N_rest"])))
```

```
noegleord = (n[n["n"] >= 50]
             .sort_values("log_ratio", ascending=False)
             .groupby("omraade")
             .head(8))

print(noegleord.groupby("omraade")["ord"].agg(list))
```

```
omraade
Andet          [sundhedspersoner, tandpleje, klinikker, patie...
Beskæftigelse  [feriedagpenge, jobafklaringsforløb, lønstrukt...
Miljø og klima  [havbrug, efterafgrøder, landbrugskommissionen...
Retsvæsen      [peberspray, postlister, prøveløsladelse, tigg...
Skat           [cfc, pvc, dbo, substanstest, retssikkerhedspa...
Uddannelse     [skolelederen, kompetencebevis, gymnasiereform...
Udlændinge     [rejselegitimation, modtagecenter, transportør...
Name: ord, dtype: object
```

Kig efter i viewer: Åbn n (eller hvad i kalder jeres variabel), og sortér efter log_ratio. Hvad står øverst, hvis I ikke har fjernet de sjældne ord?

Til diskussion:

- Sammenlign med A4. Er det nu lettere at genkende områderne?
- Nogle nøgleord er **personnavne**. Hvorfor? Hvad betyder det, hvis vi i en klyngeanalyse vil finde områderne ud fra, *hvad der tales om*?
- Hvorfor kræver vi en nedre grænse for n?

Jeres svar:

B2. Et tema, debat for debat og med usikkerhed

I slides målte vi temaer ved at lægge alle ord fra et år sammen (*Over tid*). Her måler vi i stedet **per debat** og spørger, hvor sikre tallene er. Vi bruger udlændingeordbogen fra slides.

Opgave:

```
udl = ["udlændinge", "flygtninge", "asyl", "asylansøgere",  
       "indvandrere", "integration", "opholdstilladelse", "udvisning"]
```

1. Lav kolonnen udl i lang: True for hvert ord, der står i udl.
2. Beregn for hver debat, hvor mange udlændingeord der er per 1.000 ord. Gem det som kolonnen udl i korpus.
3. Hvor stor en andel af debatterne har værdien 0? Lav en oversigt med gennemsnit, median og andel med 0 for hvert politikområde.
4. Beregn for hvert år både det samlede mål fra slides (alle ord i året lagt sammen) og gennemsnittet af debatterne. Sammenlign dem.
5. Lav et 95 %-bootstrap-interval for gennemsnittet i hvert år: træk debatter med tilbagelægning inden for hvert år 500 gange, og tag 2,5 %- og 97,5 %-fraktilen.
6. Tegn gennemsnittet og intervallet over tid.

Hjælp:

- Slides, *Mål: per 1.000 ord*: `lang["ord"].isin(kriseord)` og `lang.groupby("aar") [...].mean() * 1000`.
- Slides, *Kør den på korpuset*: `.groupby(level=0)` giver én værdi per debat.
- Preprocess-notebooken, trin 5.2: `.agg(...)` med navngivne kolonner.
- Bootstrap: `korpus.groupby("aar").sample(frac=1, replace=True, random_state=i)` trækker én ny stikprøve. Gentag med en list comprehension, og saml med `pd.concat(..., axis=1)` og `.quantile(0.025, axis=1)`.
- Slides, *Rammer data forudsigelsen?*: plotnine. Intervallet tegnes med `geom_ribbon(aes(ymin=..., ymax=...))`.

```
# Din kode her  
udl = ["udlændinge", "flygtninge", "asyl", "asylansøgere",  
       "indvandrere", "integration", "opholdstilladelse", "udvisning"]  
  
lang["udl"] = lang["ord"].isin(udl)
```

```
korpus["udl"] = lang["udl"].groupby(level=0).mean() * 1000  
  
print(korpus["udl"].describe().round(2))  
print()  
print("Andel debatter med 0:", round((korpus["udl"] == 0).mean(), 3))  
print()  
print(korpus.groupby("omraade")["udl"].agg(  
    gennemsnit="mean",  
    median="median",  
    andel_nul=lambda s: (s == 0).mean()).round(2))
```

```

count      3070.00
mean         0.38
std         1.59
min          0.00
25%          0.00
50%          0.00
75%          0.00
max         30.99
Name: udl, dtype: float64

```

Andel debatter med 0: 0.824

	gennemsnit	median	andel_nul
omraade			
Andet	0.11	0.00	0.87
Beskæftigelse	0.22	0.00	0.85
Miljø og klima	0.03	0.00	0.97
Retsvæsen	0.42	0.00	0.73
Skat	0.04	0.00	0.91
Uddannelse	0.17	0.00	0.84
Udlændinge	4.79	3.99	0.01

```

pr_aar = pd.DataFrame({
    "samlet": lang.groupby("aar")["udl"].mean() * 1000,
    "gns_debat": korpus.groupby("aar")["udl"].mean(),
}).round(2)

print(pr_aar)

```

	samlet	gns_debat
aar		
2007	0.04	0.02
2008	0.15	0.13
2009	0.26	0.20
2010	0.32	0.19
2011	0.33	0.26
2012	0.21	0.15
2013	0.30	0.32
2014	0.50	0.30
2015	0.87	0.59
2016	0.62	0.46
2017	0.67	0.67
2018	0.62	0.63
2019	0.49	0.42
2020	0.50	0.57

2021	0.38	0.32
2022	0.72	0.66

```

traek = pd.concat([korpus.groupby("aar")
                    .sample(frac=1, replace=True, random_state=i)
                    .groupby("aar")["udl"].mean()
                    for i in range(500)], axis=1)

usikkerhed = pd.DataFrame({
    "gns": korpus.groupby("aar")["udl"].mean(),
    "nedre": traek.quantile(0.025, axis=1),
    "oever": traek.quantile(0.975, axis=1),
}).round(2)

print(usikkerhed)

```


	gns	nedre	oever
aar			
2007	0.02	0.00	0.06
2008	0.13	0.07	0.20
2009	0.20	0.09	0.31
2010	0.19	0.07	0.32
2011	0.26	0.10	0.50
2012	0.15	0.05	0.26
2013	0.32	0.15	0.53
2014	0.30	0.15	0.49
2015	0.59	0.34	0.89
2016	0.46	0.25	0.67
2017	0.67	0.42	0.94
2018	0.63	0.38	0.91
2019	0.42	0.19	0.69
2020	0.57	0.26	1.03
2021	0.32	0.15	0.52
2022	0.66	0.34	1.01

```

from plotnine import ggplot, aes, geom_ribbon, geom_line, geom_point, labs,
theme_minimal

(ggplot(usikkerhed.reset_index(), aes(x="aar", y="gns"))
 + geom_ribbon(aes(ymin="nedre", ymax="oever"), alpha=0.2)
 + geom_line()
 + geom_point()
 + labs(x="År", y="Udlændingeord per 1.000 ord",
        title="Udlændingetemaet per debat, med 95 %-bootstrap-interval")
 + theme_classic())

```



Kig efter i viewer: Sortér korpus efter udl. Hvilke debatter scorer højest? Hvilket område kommer de fra?

Til diskussion:

- Hvordan ser fordelingen ud? Hvad betyder det for gennemsnittet som mål?
- Hvorfor er det samlede mål og gennemsnittet af debatterne ikke det samme? Hvilke debatter vejer mest i det samlede mål? (Tænk på A2.)
- Kan I sige, at udlændingetemaet fyldte mere i 2015-2017 end i årene før? Hvor brede er intervallerne?

Jeres svar: